

在复杂几何上重构稀疏观测的物理场

用算子定义的函数空间约束张量分解

Operator-Prior Tensor 项目组

2026 年 8 月 22 日

摘要

真实的物理场几乎从不长在干净的矩形上——楼里有墙，海里有岛，反应器里有挡板。而绝大多数用张量分解做场重构的工作，默认场长在规则的二维矩形或三维方块上。本文指出这个默认假设在复杂几何上会造成实实在在的误差：普通张量分解把网格节点当作无意义的编号，于是把浓度平滑地抹过墙；在传感器稀疏时问题更严重——未观测节点的因子行出现在零个方程里，问题不是难解，而是未定义。

我们的做法是把已知的几何装配成一个微分算子，用它的低阶特征函数作为空间因子的字典。待学参数从“每个节点一组数”降到“十几个系数”，而且每个节点都通过共享的字典与其余节点绑定。（图 1）在五个几何家族、十九种布局上，与同一个模型的几何盲版本相比（同一节点集、同一解码器、同一优化器、同一先验），十五个带几何的布局在两种采样协议下全部五个种子获胜，倍数从 1.7 到 13.9；四个无几何的对照精确并列。

我们同时给出方法的适用条件，并且它在拟合任何模型之前就能计算：几何必须真的限制住场能去哪里。受控实验表明，全密封隔间在流速极强时仍有 6.5 倍优势，而有门洞的隔间在同样流速下降到 0.95 倍——流体直接从门洞穿过去了。两个外部真实数据集落在条件之外，结果与条件一致。

目录

1 动机与背景	3
1.1 真实的物理场长在复杂几何上	3
1.2 普通张量分解为什么会错	3
1.3 传感器稀疏时，问题不是难解而是未定义	3
1.4 几何信息是免费的，材料信息不是	3
2 任务设定	4
2.1 数据与观测	4
2.2 学习器可见与不可见的信息	4
2.3 核心对照的设计	5
3 方法	5
3.1 出发点：神经张量分解，再往前一步	5
3.2 论文主线：四个公式	6

3.3	记号	7
3.4	概率模型	7
3.5	几何如何算出来：从域到 (Φ, λ)	9
3.5.1	算子	9
3.5.2	P1 有限元离散	9
3.5.3	谱基	10
3.6	推断第一段：因子的 MAP 估计	11
3.7	推断第二段：核的精确后验与证据最大化	11
3.8	预测分布与校准	12
3.9	计算：不物化设计矩阵	12
3.10	空间因子是一个函数，不是查找表	13
4	算法	13
4.1	超参数及其来历	13
5	内部工具：如何挑选合适的数据集与配置	15
6	实验	15
6.1	基准与协议	15
6.2	主结果：核心消融	17
6.3	经典方法在传感器采样下未定义	17
6.4	不是只对扩散有效	17
6.5	适用条件：几何必须仍然约束场	17
6.6	应用：几何值多少个传感器	18
7	已知边界与踩过的坑	18
8	相关工作定位	19
9	可复现性	19

1 动机与背景

1.1 真实的物理场长在复杂几何上

考虑一类常见任务：重构一栋楼里的污染物浓度、一个厂房里的温度、一片海域的水位。共同特点是**观测极其稀疏**——几十到几百个传感器，要推断几万个位置——以及一个教科书里常被忽略的事实：**域的几何是复杂的**。

- 楼里有墙，房间之间只通过门相连；
- 厂房里有设备、隔断、通风管；
- 海域有海岸线和岛屿；
- 反应器里有挡板和催化剂床层。

而绝大多数用张量方法做场重构的工作，默认场长在一个规则的二维矩形或三维方块上。一旦几何复杂起来，这个默认就开始造成错误。

1.2 普通张量分解为什么会错

把观测组织成三阶张量 $\mathcal{Y} \in \mathbb{R}^{N_1 \times N_2 \times N_3}$ ，语义是（场景，时间，空间节点）。Tucker 分解写成

$$\mathcal{Y}_{i_1 i_2 i_3} \approx \sum_{r_1, r_2, r_3} \mathcal{G}_{r_1 r_2 r_3} U_1(i_1, r_1) U_2(i_2, r_2) U_3(i_3, r_3), \quad (1)$$

其中因子矩阵 $U_m \in \mathbb{R}^{N_m \times R_m}$ 自由学习。

问题出在第三维。对式 (1) 来说，“位置”只是一个编号——1 号点、2 号点、3 号点，编号之间没有任何关系。于是它会推断“5 号点和 6 号点观测值接近，所以它们相关”。但如果这两点分别在一堵墙的两侧，它们在物理上几乎不交换任何东西，只是碰巧在欧氏距离上靠得近。

1.3 传感器稀疏时，问题不是难解而是未定义

两种采样协议给出两个不同性质的问题：

- **随机缺失**：均匀随机抽取张量条目。每个节点出现在很多观测条目里， U_3 的每一行都可估。
- **空间传感器**：选少数节点，观测它们的完整轨迹。这是真实部署的方式。

在第二种协议下，一个未被选中的节点 i_3 ，它的因子行 $U_3(i_3, \cdot)$ 出现在 **零个** 方程中。这不是数据少，是字面意义上零个约束。我们实测 CP-ALS 与 Tucker-HOOI (TensorLy 官方实现, SVD 初始化, 秩用留出集开天眼挑选, 跑满迭代) 在所有布局上**精确返回** $\text{NRMSE} = 1.000$ ，即在未观测处输出零。

这不是把基线做残废：同样两个例程在随机缺失协议下是 0.27–0.66 的正常对手。两种采样问的是两个不同的问题。

1.4 几何信息是免费的，材料信息不是

本文方法的可行性建立在一个不对称上：




图 1: 同样 1131 个传感器 (10%) 下的重构。真值 (左一) 在墙处是一道陡峭的断层; 本文方法 (左二) 还原了它, 而不知道墙的同个模型 (左三) 与坐标神经网络 (右一) 都把浓度抹过了墙, 在另一侧凭空造出不存在的污染。绿点是传感器位置的采样 (两侧拿到的完全相同)。

通常已知 (免费)	通常未知 (需要测量)
楼层平面图、墙与门的位置	空气的有效扩散率
海岸线、岛屿轮廓	水体的实际粘性
设备布局与隔断图纸	局部湍流强度

我们只使用左列。右列在生成真值时含有一个平滑的背景变化, 而学习器对此一无所知。这使得本方法的先验层级是几何先验而非已知物理——比物理信息神经网络 (PINN) 一类方法的假设弱得多, 也因此更容易在真实场景成立。

2 任务设定

2.1 数据与观测

给定张量 $\mathcal{Y} \in \mathbb{R}^{N_1 \times N_2 \times N_3}$ 与观测索引集 $\Omega \subset [N_1] \times [N_2] \times [N_3]$, $|\Omega|/(N_1 N_2 N_3)$ 取 2% 到 20%。观测值带有噪声

$$y_i = \mathcal{Y}_i + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, (0.1 \sigma_\Omega)^2), \quad i \in \Omega, \quad (2)$$

其中 σ_Ω 是观测值的标准差。目标是重构留出条目上的值, 评价指标为

$$\text{NRMSE} = \frac{\sqrt{\frac{1}{|\Omega^c|} \sum_{i \in \Omega^c} (\hat{y}_i - \mathcal{Y}_i)^2}}{\text{std}(\{\mathcal{Y}_i\}_{i \in \Omega^c})}. \quad (3)$$

$\text{NRMSE} = 1$ 相当于用留出集均值作预测。

2.2 学习器可见与不可见的信息

- **可见:** 网格 (节点坐标与单元)、障碍物的位置与形状、边界条件类型、观测索引集 Ω 、以及 Ω 上的带噪观测值。
- **不可见:** 背景材料参数的空间变化、留出条目的任何信息、真值使用的模态数。

这一条有单元测试守着: 改变真值材料时, 学习器的所有基必须逐位不变。

2.3 核心对照的设计

本文所有主结果都建立在一个只差一件事的对照上：

geometry_operator	算子知道障碍在哪里
blind_operator	同一个模型，算子不知道障碍

两者共享节点集、解码器、优化器、先验、闭式核后验、以及全部超参数。唯一区别是装配算子时是否包含障碍。因此任何性能差异**只能**来自几何信息。

更重要的是**阴性对照**：在没有障碍的布局上，两个算子是同一个数学对象，优势必须精确为 1.00。这是整个论证的支点——它排除了”提出的模型本来就更好”这一替代解释。

3 方法

3.1 出发点：神经张量分解，再往前一步

近年用张量分解做物理场重构的主流做法，是把离散的因子矩阵换成**空间的连续函数**：

$$U_3(i_3, r) \longrightarrow f_r(x_{i_3}), \quad f_r = \text{坐标网络 (MLP) 的第 } r \text{ 个输出.} \quad (4)$$

这类方法（下称神经张量分解）解决了式 (1) 把位置当编号的一半问题：它知道位置有坐标，因此相邻坐标给出相近的因子值。

但它只知道坐标，不知道**连通性**。对一个 MLP 来说，墙两侧相距 5 厘米的两点就是”相邻”，因为欧氏距离小。它必须从数据里学出墙的存在，而在稀疏观测下数据不足以支撑这件事——图 1 右一是它的典型失败：浓度被平滑地抹过墙。

比它更进一步的常见做法，是给因子加**图 Laplacian 正则**：用网格的邻接构造 Laplacian L ，在损失里加 $\text{tr}(F^\top L F)$ 。这确实把连通性引入了，但引入的方式是惩罚而非约束——因子仍然有 $N_3 \times R_3$ 个自由参数，只是被推向光滑。

本文的做法是把连通性放进**参数化**而不是惩罚项：

$$U_3 = \Phi W, \quad \Phi \in \mathbb{R}^{N_3 \times K}, W \in \mathbb{R}^{K \times R_3}, K \ll N_3, \quad (5)$$

其中 Φ 的列是**该几何上算子的低阶特征函数**。三者的关系是：

方法	空间因子的形式	自由参数（空间）
离散 Tucker/CP	自由表 U_3	$N_3 R_3$
神经张量分解	$\text{MLP}_\theta(x)$	$ \theta $
图 Laplacian 正则	自由表 + $\text{tr}(F^\top L F)$ 罚	$N_3 R_3$
本文	ΦW , Φ 由几何解出	$K R_3$

差别不只是参数量。在传感器采样下，前三者的未观测节点分别是：完全无约束、由坐标平滑性间接约束、由图上的邻居间接约束；而式 (5) 让**每个节点都出现在每一列 ϕ_k 里**，因此每个未观测节点都被同一批 $K R_3$ 个系数确定。

3.2 论文主线：四个公式

§3.4–§3.8 按实现顺序展开，便于接手的人对着代码读。但论文正文不应该那样写——那读起来像一条流水线：装配有限元、解特征问题、截断、加光滑罚。这四步合起来其实是一个对象，下面给出。

关键恒等式 我们的先验是 $W_{kr} \sim \mathcal{N}(0, (1 + \lambda_k)^{-p})$ ，因子是 $U_3(\cdot, r) = \sum_k W_{kr} \phi_k$ ，于是

$$\text{Cov}[U_3(\cdot, r)] = \sum_k (1 + \lambda_k)^{-p} \phi_k \phi_k^\top. \quad (6)$$

而算子 $\mathcal{C} = (\mathcal{I} + \mathcal{A}/\pi^2)^{-p}$ 的特征对恰好是 $((1 + \lambda_k)^{-p}, \phi_k)$ 。因此

我们的先验就是域上一个高斯过程，其协方差算子由该几何自身的微分算子给出；所谓“谱截断”就是它的 Karhunen–Loève 截断。

这不是重新解释，是等式成立。且 $(\kappa^2 - \Delta)^p$ 型精度的高斯场正是 **Whittle–Matérn 族** (Lindgren 等人的 SPDE 表示)，所以一句话可以说成：空间因子服从定义在该几何上的 *Matérn* 高斯过程先验。

于是全部方法是：

$$\text{几何} \rightarrow \text{先验:} \quad \mathcal{C} = (\mathcal{I} + \mathcal{A}/\pi^2)^{-p}, \quad \mathcal{A} = -\nabla \cdot (a(x) \nabla) + \kappa \quad (7)$$

$$\text{空间因子:} \quad U_3(\cdot, r) \sim \mathcal{GP}(0, \mathcal{C}) \xrightarrow{\text{KL 截断}} \sum_{k \leq K} w_{kr} \phi_k, \quad w_{kr} \sim \mathcal{N}(0, (1 + \lambda_k)^{-p}) \quad (8)$$

$$\text{观测模型:} \quad y_i \sim \mathcal{N}(z(i)^\top g, \beta^{-1}), \quad z(i) = \bigotimes_m \tilde{F}_m(i_m, \cdot) \quad (9)$$

$$\text{核的后验:} \quad p(g | y) = \mathcal{N}(\mu, \Sigma), \quad \Sigma = (\beta Z^\top Z + \alpha I)^{-1}, \quad \mu = \beta \Sigma Z^\top y \quad (10)$$

这样包装为什么更好

1. **几何只出现一次**——在式 (7) 的 $\mathcal{A}$ 里。有限元、网格、特征求解全部退到 (7)→(8) 的实现细节，正文不必出现。
2. **字典与先验不再是两件事**。之前要分别交代“用什么基”和“加什么罚”；现在 KL 展开同时给出两者，因为它们本来就出自同一个协方差算子。
3. **截断不再是 ad hoc**。KL 截断在均方意义下是最优的有限秩近似，所以 K 是一个近似阶数而非一个随手设的超参。
4. **接上了成熟的文献**。Matérn/SPDE 表示是高斯过程领域的标准工具，把本方法放进那个语境比自造一套术语更容易被理解，也更容易被检验。

推断：利用条件共轭结构 式 (9) 有一个可以利用的结构：

给定因子后，模型对核是线性的。

于是模型在核这一部分是条件共轭的——核的后验有精确闭式，其超参 (α, β) 也可由证据最大化直接定出；而因子非线性地进入 $z(i)$ ，没有闭式。我们据此采用与该结构对齐的推断：

参数	进入模型的方式	推断
核 g	线性 （条件共轭）	精确后验 + 证据最大化定 (α, β)
因子 $\{W_g\}, \theta, \{T_g\}$	非线性	MAP 点估计

即在共轭的那一部分做精确边缘化，在其余部分做点估计——一种部分坍塌（partially collapsed）的推断。它带来三件事： (α, β) 不需要人工设定；预测自带不确定度；有效参数个数 γ （式 (23)）给出模型实际用掉的自由度。

为什么不把因子也放进边缘似然 原则上可以把核积掉、只留边缘似然一个目标对因子求极大，形式上更统一。我们实测了这条路，它与本方法所需的秩不相容：每个梯度步都要形成 $Z^\top Z$ ，代价 $O(nP^2)$ ，而当前方案只在最后形成一次。

秩	P	当前方案/步	边缘似然/步	倍数
(4, 4, 6)	96	32.9 ms	35.0 ms	$1.1 \times$
(8, 6, 10)	480	23.9 ms	58.9 ms	$2.5 \times$
(12, 10, 16)	1920	21.9 ms	404.8 ms	$18.5 \times$

代价按 P^2 增长，而 $P = 1920$ 正是我们所用的值——单次拟合从 33 秒变成 10 分钟。在小核上两者代价相当，但小核恰好是被证明会导致秩受限、把主表低估三倍的那个配置 (§7)。

更重要的是，**这个近似是良性的**。在代价尚可承受的秩 (8, 6, 10) 上直接比较两者，精度几乎相同，估出的超参也在同一量级：

目标	NRMSE	α	β
当前方案（因子 MAP + 核精确后验）	0.0307	4.8×10^2	9.33×10^1
边缘似然（核积掉，对因子求极大）	0.0300	6.3×10^2	9.40×10^1

所以这个分工不是“只能这样做”，而是**精确做也是同一个结果，但贵 18 倍**：它把 $O(nP^2)$ 的那一步从每步一次降到全程一次，使方法在能真正兑现基的秩上仍然可算。

一个更优美但未验证的变体 式 (8) 的截断让参数量与网格规模无关 (KR_3 而非 N_3R_3)，这正是稀疏传感器情形能用 288 个参数工作的原因。若不截断，而直接以稀疏精度矩阵 $(M + K/\pi^2)^p$ 作为 U_3 的高斯马尔可夫随机场先验，则**不需要特征分解，截断阶数 K 也随之消失**——未观测节点仍通过精度矩阵的邻接被约束。代价是参数量回到 N_3R_3 。这是值得做的后续方向，本文未验证，故只记录而不列入主线。

3.3 记号

3.4 概率模型

写出完整的生成式模型，后面每一步推断都对应其中一项。

表 1: 全文记号。

符号	含义
$\mathcal{Y} \in \mathbb{R}^{N_1 \times N_2 \times N_3}$	观测张量, 语义 (场景, 时间, 空间节点)
$\Omega \subset [N_1] \times [N_2] \times [N_3]$	观测索引集, $n = \Omega $
$y \in \mathbb{R}^n$	Ω 上的带噪观测值
$\mathcal{S} \subset [N_3]$	被观测到的空间节点集合 (传感器位置)
$\Omega_{\text{dom}} \subset \mathbb{R}^d$	物理域
φ_i	节点 i 的 P1 帽子函数
$K, M \in \mathbb{R}^{N_3 \times N_3}$	刚度矩阵与质量矩阵 (稀疏)
$\Phi = [\phi_1, \dots, \phi_K]$	谱基, $\Phi^\top M \Phi = I$
$\lambda = (\lambda_1, \dots, \lambda_K)$	对应特征值, $\lambda_1 \leq \dots \leq \lambda_K$
$g \in \{1, \dots, G\}$	坐标组的编号 (本文 $G = 3$)
$W_g \in \mathbb{R}^{K_g \times R_g}$	算子组的谱系数 (待学)
θ	神经组的网络参数 (待学)
T_g	自由表组的因子矩阵 (待学)
$\tilde{F}_g$	逐列单位 RMS 归一化后的因子
$\mathcal{G} \in \mathbb{R}^{R_1 \times R_2 \times R_3}$	Tucker 核, $g = \text{vec}(\mathcal{G}) \in \mathbb{R}^P$, $P = \prod_m R_m$
$Z \in \mathbb{R}^{n \times P}$	设计矩阵, 第 i 行为 $z(i)^\top$
α	核先验精度 (待估)
β	噪声精度 (待估)
μ, Σ	核的后验均值与协方差
γ	有效参数个数
c	预测标准差的校准系数

似然 给定所有因子与核,

$$p(y \mid \{W_g\}, \theta, \{T_g\}, g; \beta) = \prod_{i \in \Omega} \mathcal{N}(y_i \mid z(i)^\top g, \beta^{-1}), \quad (11)$$

其中设计向量由归一化后的因子行逐行 Kronecker 积给出

$$z(i) = \tilde{F}_1(i_1, \cdot) \otimes \tilde{F}_2(i_2, \cdot) \otimes \tilde{F}_3(i_3, \cdot). \quad (12)$$

关键结构性质：给定因子后，模型对核 g 是线性的——这正是后文能对核做闭式后验的原因。

核的先验 各向同性高斯

$$p(g \mid \alpha) = \mathcal{N}(g \mid 0, \alpha^{-1} I_P). \quad (13)$$

谱系数的先验：几何在这里进入 这是本文的核心。对算子组 g ,

$$p(W_g) = \prod_{k=1}^{K_g} \prod_{r=1}^{R_g} \mathcal{N}(W_{g,kr} \mid 0, [\rho(1 + \lambda_{g,k})^p]^{-1}), \quad p = 1.5. \quad (14)$$

即第 k 个模态的系数，其先验精度按 $(1 + \lambda_{g,k})^p$ 增长。 $\lambda_{g,k}$ 是几何算子的特征值，所以：

- 几何决定了哪些空间形状算低频——这些形状在墙处断开、在门洞处连通；
- 先验说低频形状可以有系数、高频形状必须小；
- 因此几何同时决定了字典和先验的形状。这不是“先有字典再加个光滑罚”，两者出自同一个算子。

$(1 + \lambda)^p$ 正是 Sobolev 范数 $\|u\|_{H^p}^2$ 在该算子特征基下的权重，所以式 (14) 等价于对函数施加 H^p 光滑性先验——但是在几何意义下的 H^p ，不是欧氏意义下的。

其余组的先验 自由表组（若给定罚算子 P_g ）取 $p(T_g) \propto \exp\{-\frac{\rho}{2} \text{tr}(T_g^\top P_g T_g)\}$ ；神经组取 $p(\theta) = \mathcal{N}(0, \rho^{-1} I)$ 。

3.5 几何如何算出来：从域到 (Φ, λ)

上一节把 Φ, λ 当作已知。它们由域与障碍物唯一确定，过程不接触任何数据。

3.5.1 算子

取扩散型算子 $\mathcal{A}u = -\nabla \cdot (a(x) \nabla u) + \kappa u$ ，障碍物实现为 $a(x)$ 取极小值的薄带（对比度 100:1，理由见 §7）。

3.5.2 P1 有限元离散

把域剖成单纯形。对每个节点 i 定义帽子函数 φ_i ：在节点 i 上取 1，其他节点上取 0，单元内线性。它们张成所有分片线性连续函数的空间，于是

$$u(x) = \sum_i u_i \varphi_i(x), \quad (15)$$




图 2: 拟合之前的字典 Φ , 不含任何数据。上行是几何算子的特征函数——在墙处断开、在门洞处连通; 中行是忘了墙的同—算子, 给出无视墙的平滑斜坡; 下行是把楼当成矩形的可分基。式 (14) 的先验精度 $(1+\lambda_k)^p$ 也由同一个算子给出, 所以几何同时决定了字典和先验。

u_i 是它在节点 i 上的值——函数与节点值向量一一对应 (见 §3.10)。

在单元 T 内用重心坐标描述。设顶点 $p_0, \dots, p_k$, 边矩阵 $E = [p_1 - p_0; \dots; p_k - p_0] \in \mathbb{R}^{k \times n}$ 。由 $x - p_0 = E^\top \lambda_{1:k}$ 左乘 E :

$$\lambda_{1:k} = (EE^\top)^{-1}E(x - p_0) \implies \nabla \lambda_{1:k} = (EE^\top)^{-1}E, \quad \nabla \lambda_0 = -\sum_{i \geq 1} \nabla \lambda_i. \quad (16)$$

单元体积 $|T| = \sqrt{\det(EE^\top)}/k!$, 于是单元矩阵为

$$K_{ij}^T = a_T |T| \nabla \lambda_i \cdot \nabla \lambda_j, \quad M_{ij}^T = \frac{|T|}{(k+1)(k+2)} (1 + \delta_{ij}), \quad (17)$$

累加到全局得稀疏 K, M 。

准则 1 (同一公式覆盖三种几何). $EE^\top$ 是诱导度量。 $k = n = 2$ 是平面三角形, $k = n = 3$ 是四面体, $k = 2, n = 3$ (三维中的曲面三角形) 时式 (17) 自动给出 **Laplace–Beltrami** 算子。球面因此不需要特殊代码, 只需要一张不同的网格; 该性质由球面特征值必须等于解析解 $l(l+1)$ 的测试守护。

3.5.3 谱基

$$K\phi_k = \lambda_k M\phi_k, \quad \Phi^\top M\Phi = I. \quad (18)$$

质量正交归一不是形式讲究: 在非均匀网格上, 普通欧氏正交会让节点密度而非函数频率决定什么算低频。

实现用移位反演 Lanczos, 移位 $\sigma = -10^{-6}$ (纯 Neumann 算子在 0 处奇异)。代价与请求的模态数成正比而非 N_3^3 : 642 节点的球面谱从稠密路径的 32.0 秒降到 0.11 秒; 40 962 节点稠密不可行、稀疏 35.6 秒。两条路径在都能跑的网格上给出 逐位相同的张量, 特征值差 5.7×10^{-13} 。

3.6 推断第一段：因子的 MAP 估计

联合后验对 $(\{W_g\}, \theta, \{T_g\}, g)$ 不可解析。我们采取**分层近似**：先对因子取 MAP 点估计，再在因子固定的条件下对核做精确后验。

取式 (11)–(14) 的负对数并丢掉常数，MAP 目标为

$$\mathcal{L} = \frac{1}{n} \sum_{i \in \Omega} (z(i)^\top g - y_i)^2 + \beta_{\text{reg}} \left[\underbrace{\overline{g^2}}_{\text{核先验}} + \underbrace{\sum_g \frac{1}{K_g R_g} \sum_{k,r} (1 + \lambda_{g,k})^p \widetilde{W}_{g,kr}^2}_{\text{谱先验, 式 (14)}} \right], \quad (19)$$

$\beta_{\text{reg}} = 2 \times 10^{-3}$ 吸收了 ρ/β 的比值。用 AdamW 优化 (学习率 3×10^{-3} , 权重衰减 10^{-6} , 梯度裁剪 5.0, $T = 1500$ 步, 冷随机初始化, 无早停), **保留目标值最优的检查点而非最后一步**。

归一化的作用 $\tilde{F}$ 是逐列单位 RMS 归一化的。这让先验与因子尺度无关, 也让不同组可比。代价是因子的整体尺度不可辨识——但它被核吸收, 而核正是下一段唯一做完整后验的对象, 所以这个不可辨识性不影响不确定度量化。

3.7 推断第二段：核的精确后验与证据最大化

固定 $\tilde{F}$ 后, 由式 (11) 与 (13), 核的条件后验是精确高斯:

$$p(g | y, \alpha, \beta) = \mathcal{N}(g | \mu, \Sigma), \quad \Sigma = (\beta Z^\top Z + \alpha I)^{-1}, \quad \mu = \beta \Sigma Z^\top y. \quad (20)$$

α, β **从数据自己定** 对核做边缘化, 得到**证据**

$$p(y | \alpha, \beta) = \int \mathcal{N}(y | Zg, \beta^{-1}I) \mathcal{N}(g | 0, \alpha^{-1}I) dg, \quad (21)$$

其对数为

$$\log p(y | \alpha, \beta) = \frac{P}{2} \log \alpha + \frac{n}{2} \log \beta - \frac{\beta}{2} \|y - Z\mu\|^2 - \frac{\alpha}{2} \|\mu\|^2 - \frac{1}{2} \log |\beta Z^\top Z + \alpha I| - \frac{n}{2} \log 2\pi. \quad (22)$$

对 α, β 求导置零, 得 MacKay 不动点。记 $Z^\top Z$ 的特征值为 $\{\ell_k\}$, 定义**有效参数个数**

$$\gamma = \sum_{k=1}^P \frac{\beta \ell_k}{\beta \ell_k + \alpha} = P - \alpha \text{tr}(\Sigma) \in [0, P], \quad (23)$$

则

$$\boxed{\alpha \leftarrow \frac{\gamma}{\|\mu\|^2}, \quad \beta \leftarrow \frac{n - \gamma}{\|y - Z\mu\|^2}} \quad (24)$$

交替迭代式 (20) 与 (24) 至收敛 (至多 80 次)。

γ 的含义值得说明: 式 (23) 中每一项 $\beta \ell_k / (\beta \ell_k + \alpha)$ 落在 $[0, 1]$, 衡量第 k 个方向被数据确定的程度——数据信息 $\beta \ell_k$ 远大于先验精度 α 时接近 1, 反之接近 0。因此 γ 是”实际被用掉的参数个数”, 而 $P - \gamma$ 是被先验压住的部分。

准则 2 (在特征基中迭代). $Z^\top Z$ 在整个循环中不变。做一次对角化 $Z^\top Z = V\Lambda V^\top$, 记 $b = V^\top Z^\top y$, $\pi = \beta\lambda + \alpha$, 则

$$\tilde{\mu} = \beta b \odot \pi, \quad \text{tr}(\Sigma) = \sum_k \pi_k^{-1}, \quad \|y - Z\mu\|^2 = \|y\|^2 - 2\tilde{\mu}^\top b + \sum_k \lambda_k \tilde{\mu}_k^2,$$

每次迭代从 $O(P^3)$ 降到 $O(P)$ 。 $P = 1920$ 时这是” 整个拟合被这个循环主导” 与” 不被主导” 的差别。

这一层贝叶斯买到了什么 (i) 核的正则强度 α 与噪声水平 β 不需要人工设定, 由证据自动定; (ii) 得到预测的不确定度 (下一节); (iii) γ 给出模型实际用掉的自由度, 可用于诊断。

明确没有做的 因子上没有后验。这是刻意的取舍, 代价是明确的: 我们尝试过用 per-column ARD 自动确定谱截断 K , 失败且原因是结构性的——点估计的 ARD 不动点 $\alpha_k = R / \sum_r W_{kr}^2$ 缺少后验协方差项, 罚项对每列恒为 ρR , 什么都剪不掉 (§7)。要真正剪枝需要因子上的后验。

3.8 预测分布与校准

对任一条目, 把核边缘化掉, 预测分布为高斯:

$$p(y_* | y) = \mathcal{N}\left(y_* \mid z_*^\top \mu, \underbrace{z_*^\top \Sigma z_*}_{\text{参数不确定}} + \underbrace{\beta^{-1}}_{\text{观测噪声}}\right). \quad (25)$$

为什么还要校准 式 (25) 只反映了核的不确定性。因子是点估计, 它们的不确定性没有被计入, 所以式 (25) 会 **系统性低估**。我们用留一交叉验证做一次标量校正: 记杠杆值 $h_i = \beta z_i^\top \Sigma z_i$, 留一残差与其标准差为

$$e_i^{\text{loo}} = \frac{y_i - z_i^\top \mu}{1 - h_i}, \quad s_i = \sqrt{\beta^{-1} + z_i^\top \Sigma z_i}, \quad (26)$$

取

$$c = \text{clip}\left(\frac{Q_{0.95}(|e_i^{\text{loo}}|/s_i)}{1.96}, 0.5, 4\right), \quad \sigma_* = c\sqrt{z_*^\top \Sigma z_* + \beta^{-1}}. \quad (27)$$

取 95 分位而非标准差, 是为了不被少数离群残差主导; 除以 1.96 使得 $c = 1$ 对应” 经验 95% 区间恰好等于高斯 95% 区间”。截断在 $[0.5, 4]$ 防止极端情形。

3.9 计算: 不物化设计矩阵

朴素实现显式构造 Z 。当 $P = 1920$ 、 $n = 65\text{k}$ 时, Z 是 1.25×10^8 个数 (500 MB), 且每个梯度步重建一次。改为按模态依次收缩:

$$t_{n,r_2r_3}^{(1)} = \sum_{r_1} \tilde{F}_1 \mathcal{G}_{r_1 r_2 r_3}, \quad t_{n,r_3}^{(2)} = \sum_{r_2} \tilde{F}_2 t_{n,r_2 r_3}^{(1)}, \quad \hat{y}_n = \sum_{r_3} \tilde{F}_3 t_{n,r_3}^{(2)}, \quad (28)$$

结果完全相同 (float32 下差 2.4×10^{-6} , 对角核精确为 0), 算术量约 2.4 倍少, 峰值内存降一个数量级。

CP 是同一模型的对角核特例 令 $R_1 = R_2 = R_3 = R$, $\mathcal{G}_{r_1 r_2 r_3} = w_r \delta_{r_1 r_2 r_3}$, 式 (12) 的 Kronecker 积退化为 Khatri–Rao 积, $P = R$ 。意义在于: CP 基线与本方法共享优化器、归一化、先验和闭式后验, 两者的差异只能来自模型本身。

3.10 空间因子是一个函数，不是查找表

由式 (15), Φ 的每一列是一个 P1 函数，矩阵只是它的节点迹。在任意点求值即重心插值：

$$u(x) = \sum_{i \in T(x)} \lambda_i(x) u_i. \quad (29)$$

因此本模型与神经张量分解一样可以在域内任意位置求值，只是求值方式从”前向过一个 MLP”换成”单元内重心插值”，而式 (25) 的后验原样沿用。

实测 (5520 节点上拟合，在 4000 个非节点位置查询，与独立的 34355 节点细网格真值比较)：非节点位置 NRMSE = 0.0278，节点上 = 0.0265，相差 5%。

三个边界：(i) P1 插值在网格尺度上是二阶的，神经场原则上更光滑，但我们在墙处的断裂是精确的；(ii) 域外无定义，而”墙外面没有场”本来就是正确答案；(iii) 自由表不能插值——两个类别标签之间没有中点，代码对此报错而非静默插值。

4 算法

算法 1 构造几何字典（离线，一次性，不接触数据）

输入： 域 Ω ；障碍集合 $\mathcal{O}$ ；基的列数 K

输出： 谱基 $\Phi \in \mathbb{R}^{N \times K}$ （满足 $\Phi^\top M \Phi = I$ ）；特征值 λ

- 1: 剖分域：抖动格点 + Delaunay ▷ irregular_fem.build_mesh
 - 2: 学习器材料： $a(x) \leftarrow 1$ 于背景， $a(x) \leftarrow 10^{-2}$ 于 $\mathcal{O}$ ▷ 信息层级分界线
 - 3: 装配 K, M ：按式 (17) 逐单元累加 ▷ simplex_fem.assemble_sparse
 - 4: 求最低 K 个广义特征对：移位反演 Lanczos, $\sigma = -10^{-6}$ ▷ sparse_eigenpairs
 - 5: 返回 Φ, λ
-

4.1 超参数及其来历

表 2: 冻结的超参数值。每一个都有明确来历，而非试出来的。

符号	配置键	值	怎么定的
K	basis_cutoff	逐家族 16/32/48	两条规则同时满足 (§5)
(R_1, R_2, R_3)	ranks	(12, 10, 16)	提到 headroom 落进 1.0–1.5 为止
p	power	1.5	沿用冻结的一维实验
β_{reg}	reg	2×10^{-3}	同上
T	steps	1500	收敛测试：1500 $\rightarrow$ 4000 无变化
障碍传导率	barrier	10^{-2}	物理论证 (§7)
网格分辨率	resolution	逐家族	由最小几何特征尺度定
观测噪声	noise	0.10	观测标准差的比例

算法 2 两段式拟合

输入： 各组基 $\{\Phi_g, \lambda_g\}$; 观测索引 Ω 与观测值 y ; 秩 (R_1, R_2, R_3) ; p ; β_{reg} ; 步数 T

输出： 因子参数 $\{W_g\}$; 核后验 (μ, Σ) ; 超参 (α, β) ; 校准 c

第 0 步：可观测性筛选（只读掩码，不读数据）

1: $v_k \leftarrow \frac{\sum_{i \in \mathcal{S}} \phi_k(i)^2}{\sum_i \phi_k(i)^2} / \frac{|\mathcal{S}|}{N}$; 保留 $\{k : v_k \geq 0.1\} \cup \{1\}$

第一段：因子

2: **对** $t = 1, \dots, T$ **执行**

3: $\tilde{F}_g \leftarrow \text{normcol}(F_g)$ 对每组 g

4: 按模态收缩求 $\hat{y}$ （不物化 Z ）

5: 按式 (19) 求 $\mathcal{L}$, AdamW 更新, 梯度裁剪 5.0

6: 若 $\mathcal{L}$ 为历史最优则记录检查点

7: 载回最优检查点

▷ 不是最后一步的迭代

第二段：核（闭式，无梯度）

8: $Z^\top Z = V \Lambda V^\top$

▷ 只分解一次

9: $b \leftarrow V^\top Z^\top y$; $\alpha \leftarrow 1$; $\beta \leftarrow 25$

10: **对** $j = 1, \dots, 80$ **或至收敛 执行**

11: $\pi \leftarrow \beta \lambda + \alpha$; $\tilde{\mu} \leftarrow \beta b \odot \pi$; $\gamma \leftarrow p - \alpha \sum_k \pi_k^{-1}$

12: $\alpha \leftarrow \gamma / \|\tilde{\mu}\|^2$; $\beta \leftarrow (|\Omega| - \gamma) / (\|y\|^2 - 2\tilde{\mu}^\top b + \sum_k \lambda_k \tilde{\mu}_k^2)$

13: $\Sigma \leftarrow V \text{diag}(\pi^{-1}) V^\top$; $\mu \leftarrow \beta V(b \odot \pi)$

14: 由杠杆值修正的留一残差求校准系数 c

15: **返回** $\{W_g\}, \mu, \Sigma, \alpha, \beta, c$

算法 3 预测（含任意位置）

输入： 查询索引; 因子 $\{\tilde{F}_g\}$; (μ, Σ, β, c) ; **可选：** 查询坐标 x 与网格

输出： 均值 $\hat{y}$ 与标准差 σ

1: **若** 在网格节点上查询 **则**

2: $z(i) \leftarrow$ 因子行的逐行 Kronecker 积

3: **否则**

4: $\tilde{F}_3(x, \cdot) \leftarrow \sum_{i \in T(x)} \lambda_i(x) \tilde{F}_3(i, \cdot)$

▷ 重心插值, §3.10

5: $z(x) \leftarrow$ 以插值行替换空间那一组后的 Kronecker 积

6: $\hat{y} \leftarrow z^\top \mu$; $\sigma \leftarrow c \sqrt{z^\top \Sigma z + \beta^{-1}}$

7: **返回** $\hat{y}, \sigma$

5 内部工具：如何挑选合适的数据集与配置

本节不进入论文正文。这里的量是我们自己在筛选数据集、确定分辨率与截断阶数时使用的工具——它们只用真值张量、候选基与观测掩码，在拟合任何模型之前就能算出来，因此能在花费 GPU 时间之前判断一个设定值不值得跑。把它们写下来是为了让接手的人不必重新踩一遍坑，而不是作为方法的组成部分。

投影残差（基能否张成这个场） 用途：判断一个候选数据集有没有几何信号。若几何盲基与几何感知基的残差之比接近 1，这个设定就没有可争的东西，不必跑。

$$\varepsilon(\Phi) = \frac{\|\mathcal{Y} - \mathcal{Y} \times_3 (Q Q^\top)\|_F}{\|\mathcal{Y}\|_F}, \quad Q = \text{qr}(\Phi), \quad (30)$$

即偏差下限。实现必须写成 $Q(Q^\top \mathcal{Y})$ 而非 $(Q Q^\top) \mathcal{Y}$ ，否则要物化 $N \times N$ 的投影算子。

可观测性（这个模态在传感器上被激发吗） 用途：诊断诡异的失败。

$$v_k = \frac{\sum_{i \in \mathcal{S}} \phi_k(i)^2}{\sum_i \phi_k(i)^2} \bigg/ \frac{|\mathcal{S}|}{N}. \quad (31)$$

局域在薄障碍内部的模态，特征值是全谱最低的，但传感器几乎不可能落在薄墙里。这样的模态系数完全无约束，模型会用它外推出荒谬的值——我们实测到 NRMSE 1.246、预测范围 $[-74.8, 77.8]$ 而真值在 $[-5.8, 10.4]$ ，其可见度为 $v_5 \dots v_8 = 0.004, 0.001, 0.001, 0.002$ 。

Headroom（秩能否兑现这个基） 用途：判断当前的比较是否有意义。这是本项目代价最大的一课，见 §7。

$$\text{headroom} = \frac{\text{实际达到的 NRMSE}}{\text{该模型自身的投影残差}}. \quad (32)$$

远大于 1 意味着拟合是秩受限的，此时任何关于函数空间的比较**不成立**——所有方法被同一个与几何无关的天花板压着。健康值在 1.0–1.5。

准则 3 (两条 cutoff 规则必须同时满足). (i) **近似能力对齐**： K 要让几何感知的偏差下限跨设定可比（本文取 ≈ 0.02 ）；(ii) **可辨识性**： $K \times R_3$ 不得超过传感器数 $|\mathcal{S}|$ 。两条冲突时方法就在适用区之外。

6 实验

6.1 基准与协议

冻结配置：张量 $(12, 12, N)$ ，观测 10%，噪声 10%， $\text{ranks} = (12, 10, 16)$ ，1500 步，五个全新种子 201–205。**没有选择/确认两段**，因为没有任何配置是在这些数字上选的——障碍对比度、 K 、模态筛选、步数、分辨率全部由拟合前诊断或收敛测试定下。

对照模型：blind_operator（核心消融）、flat_chart（按轴分解）、neural_tucker 与 neural_cp（坐标网络）、cp_als 与 tucker_als（TensorLy, SVD 初始化，秩用留出集开天眼挑选）、permuted（打乱索引-算子对齐的破坏性对照）。

表 3: 五个几何家族, 共 19 种布局。每个家族含一个”无几何”的阴性对照。

家族	几何机制	几何盲对照	节点数	K
plane_barrier	方形内的薄隔板	同一算子、去掉隔板	5 520	16
plane_domain	孔洞与凹角	无视孔洞的重新剖分	3 941–5 520	16
volume_barrier	立方体内的隔墙	同一算子、去掉隔墙	8 000	48
sphere	闭曲面曲率 (浅水)	lat-lon 可分图表基	10 242	32
floorplan	房间与门洞 (米制)	同一算子、去掉墙	11 310	16

表 4: 留出 NRMSE, 10% 传感器观测, 五个种子。前四行是阴性对照: 没有几何时两个算子是同一对象, 优势必须为 1.00。

家族	布局	ours	去掉几何	倍数	配对胜	神经 Tucker
plane_barrier	open	0.021	0.021	1.00	2/5	1.50
plane_domain	square	0.021	0.021	1.00	2/5	1.51
volume_barrier	open	0.039	0.039	1.00	4/5	1.73
floorplan	open_plan	0.018	0.018	1.00	—	2.83
plane_domain	center_hole	0.020	0.035	1.73	5/5	1.56
plane_domain	two_holes	0.020	0.048	2.40	5/5	2.16
plane_domain	L_shape	0.019	0.046	2.39	5/5	1.79
plane_domain	U_shape	0.019	0.045	2.35	5/5	1.83
plane_barrier	arc	0.055	0.167	3.07	5/5	2.72
plane_barrier	chamber	0.048	0.178	3.70	5/5	1.55
plane_barrier	labyrinth	0.051	0.227	4.47	5/5	1.95
floorplan	corridor	—	—	4.51	5/5	—
floorplan	apartment	—	—	8.23	5/5	—
plane_barrier	sealed_4	0.029	0.267	9.19	5/5	2.54
floorplan	lab_suite	—	—	11.44	5/5	—
sphere	open_ocean	0.041	0.563	13.91	5/5	1.28

已知例外: volume_barrier 的三个带隔墙布局为 0.99–1.48, 机制见 §7。

6.2 主结果：核心消融

三点同时成立：

1. 四个阴性对照精确并列，配对胜率是随机的（2/5、4/5）。这排除了”提出的模型本来就更好”这一解释——差距只能来自几何。
2. 十五个带几何的布局在两种协议下全部 5/5 获胜，倍数 1.73–13.91。
3. 二维十个布局全部战胜坐标网络（1.50–2.72 倍），且参数少一个数量级（288 对 2982）。空间结构不需要学，几何已经给了。

6.3 经典方法在传感器采样下未定义

表 5: 经典张量补全按协议分裂。SVD 初始化，秩用留出集开天眼挑选，跑满迭代。

	随机缺失 10%	传感器 10%
CP-ALS	0.27–0.66	1.000 (所有布局、所有秩)
Tucker-HOOI	0.27–0.66	1.000 (同上)

未观测节点出现在零个方程中，故在那里精确输出零。同样两个例程在随机缺失下是正常对手——两种采样问的是两个不同的问题。

6.4 不是只对扩散有效

同一套十个二维几何，把抛物型换成阻尼双曲型（ $K = 64$ ，随机缺失 10%，三个种子）：

布局	ours	去掉几何	倍数	神经 Tucker
open (对照)	0.096	0.096	1.00	1.31
labyrinth	0.122	0.220	1.80	1.94
arc	0.118	0.237	2.01	2.50
sealed_4	0.085	0.237	2.79	2.26

6.5 适用条件：几何必须仍然约束场

给真值加入无散度胞流（速度在隔板内部为零，几何一如既往真实），学习器的算子、基、网格、隔板全部不动：

布局	Pe	ours	去掉几何	倍数
chamber (有开口)	0	0.012	0.206	17.7
	100	0.013	0.012	0.95
sealed_4 (全密封)	0	0.026	0.279	10.7
	100	0.033	0.215	6.5

两条曲线终点不同才是结论。对流本身并不破坏算子先验：全密封布局在对流强过扩散一百倍时仍有 6.5 倍优势，因为再快的输运也过不去一堵封死的墙；有开口的布局则被对流把场直接搬过开口，优势精确归零。

准则 4 (适用条件). 几何必须仍然约束场能去哪里。动力学能绕开的障碍，不再是几何。

两个外部真实数据集落在条件之外，结果与条件一致：RealPDEBench 圆柱绕流（PIV 实测， $Re\ 1875\text{--}11\,625$ ）为 1.00–1.08 倍；CFDBench 方腔流 24 种长宽比为 0.74–1.07 倍。圆柱是开放通道里的孤立小障碍，方腔是开放盒子——流体想去哪去哪，没有约束可供算子编码。**这不是方法失败，是问题不在适用区，而且该判断在跑任何模型之前就能做出。**

6.6 应用：几何值多少个传感器

表 6: floorplan/apartment (11 310 节点, 三个种子)。

传感器	ours	去掉几何	神经 Tucker
113 (1%)	0.040	0.194	0.228
566 (5%)	0.025	0.180	0.172
2 262 (20%)	0.020	0.177	0.160




图 3: 精度对传感器数量。红线持续下降，蓝绿两条早早躺平。两个楼层平面上基线在任何测试预算下都达不到目标精度；合成布局上它们最终能到，代价是 8 倍传感器。

基线在 20 倍预算下仍达不到我们 1% 预算的精度，而且从 1% 到 20% 几乎不动 ($0.194 \rightarrow 0.177$)。它们不是数据不够，是函数空间放不下墙上的断层，加传感器补不上。合成的 `sealed_4` 上基线最终能追上，代价是 8 倍传感器。

7 已知边界与踩过的坑

三维强隔板布局 坐标网络更好 (0.51–0.85 倍)。机制清楚：三维达到同等近似质量的模态数按 k^d 增长，而 K 被可辨识性顶死 (8000 节点、800 传感器、 $48 \times 16 = 768$ 已贴边)。消融在最好配置上也最强 (1.50 倍)，说明卡住的是截断而非几何。

秩从别的实验照搬（代价最大的一个） $\text{ranks} = (4, 4, 6)$ 来自 $18 \times 24 \times 24$ 的一维实验，被原样搬到 5000–11000 节点的网格上从未复查。后果是整张主表被低估：`sealed_4` 的消融从 2.98 变成 9.73 倍，对神经方法从 1.26 变成 2.68 倍。Headroom 就是为了防止此类问题复发。

分辨率未按障碍尺度校验（犯了两次） 障碍比一个单元还薄时结果不可信，且偏差方向不可预测：一次让隔板显得更厚而**夸大优势** ($6.28 \rightarrow$ 收敛值 $3.2\text{--}4.0$)，一次让墙漏水而**低估优势**（分辨率 90 给 $3.4/4.0/10.1$ ，130 给 $5.2/9.9/13.9$ ）。

障碍对比度 10^{-3} 时隔板自身的弛豫比场还慢，它变成独立的慢子系统，任何截断基都得把前几个模态花在墙里面。 10^{-2} (100:1) 才是方法适用的区间。

谱 ARD 无法剪枝（结构性） 点估计的 ARD 不动点缺少后验协方差项，罚项对每列恒为常数，什么都剪不掉。要真正剪枝需要因子上的后验，而那正是本方法明确不做的部分。

基线初始化 Tucker-HOOI 在随机初始化下发散到 NRMSE 3–20。看上去像大幅领先，实际是基线坏了。换 SVD 初始化后它是正常对手。**基线必须以最好状态出场。**

8 相关工作定位

张量分解与补全 我们不提出新的分解结构，而是**约束因子所在的函数空间**。在随机缺失下经典方法是正常对手；在传感器采样下它们的问题是未定义的——这是结构性对比，而非精度差距。

连续/函数型张量分解与隐式神经表示 同样让因子是空间的函数，但**函数空间的来源不同**：它们从数据里学出空间结构，我们直接从已知几何解出来。参数量差一个数量级，且坐标网络对”哪些点在物理上相邻”没有先验——这正是它把浓度抹过墙的原因。

图 Laplacian 正则与流形学习 这是最近的邻居，必须正面处理。区别有二：(i) 我们的算子来自已知的物理几何（有限元装配、真实边界条件与材料对比度），不是从数据估计的相似度图；(ii) 我们做了 2×2 消融把”几何”与”表示形式”分开，结论是**几何是活性成分**，而**截断是让几何可用的那一步**。

物理信息机器学习与算子学习 信息层级不同：我们不假设已知方程，只假设已知几何。这比 PINN 一类的假设弱得多，也因此更容易在真实场景成立。

9 可复现性

全部主表数据由代码生成，**不依赖任何外部文件**，装好 `torch/numpy/scipy/tensorly` 即可在任何机器上复现，不需要网格库。

```
export PYTHONPATH=src
python -m pytest -q                # 64 项
python experiments/check_install.py # 秒级；无障碍时比值必须精确为 1.00
```

```
python experiments/run_geometry_main.py --config configs/main.yaml \  
    --families plane_barrier --output results/my_run
```

超参数全部位于 `configs/*.yaml`；命令行覆盖文件，合并结果写入产物的 `configuration` 字段，因此一个数字永远不会被归因到它没有真正使用过的设定上。

详细文档见 `docs/HANDOVER_ZH.md`（方法、推导、算法表、从零跑动指南、全部实验设定）与 `docs/DATASETS.md`（数据来源与从零重建）。